

# Teoria de Resposta ao Item Estimação

Antonio Eduardo Gomes  
aegomes@unb.br

$U_{ij} = 1$  se o  $j$ -ésimo indivíduo fornece resposta positiva (ou correta) para o  $i$ -ésimo item,  
e  $U_{ij} = 0$  se o  $j$ -ésimo indivíduo fornece resposta negativa (ou incorreta) para o  $i$ -ésimo item,  
 $i = 1, \dots, l; j = 1, \dots, n$  onde  
 $l$  é o número de itens no questionário, e  
 $n$  é o número de respondentes (indivíduos).

Considere o ML3

$$P(U_{ij} = 1 \mid \theta_j) = c_i + \frac{1 - c_i}{1 + \exp[-a_i(\theta_j - b_i)]} ,$$

para o qual abordaremos as possibilidades de estimação dos parâmetros dos itens (chamados de “parâmetros estruturais”) e as proficiências (chamadas de “parâmetros incidentais”).

Para facilitar a estimação dos parâmetros dos itens (conhecida como “calibração”), bem como das proficiências, são assumidas as seguintes suposições:

- i) unidimensionalidade do traço latente (proficiência), i.e., o teste deve ser construído de tal modo que os itens estejam medindo um único traço latente;
- ii) as respostas de indivíduos diferentes são independentes;
- iii) para um valor fixado do traço latente, as respostas para os diferentes itens são independentes (independência local);

Obs.: Na verdade, é possível mostrar que a unidimensionalidade implica a independência local.

Considere os vetores de parâmetros  $\gamma = (\gamma_1, \dots, \gamma_l)$  com  $\gamma_i = (a_i, b_i, c_i)$ ,  $i = 1, \dots, l$ , e  $\Theta = (\theta_1, \dots, \theta_n)$ . Sejam  $u_{ij}$  valores possíveis das variáveis  $U_{ij}$ ,  $i = 1, \dots, l$ , e  $j = 1, \dots, n$ .

A função de verossimilhança é dada por

$$\begin{aligned} L(\gamma, \Theta) &= \prod_{j=1}^n \prod_{i=1}^l [P(U_{ij} = 1 \mid \theta_j)]^{u_{ij}} [P(U_{ij} = 0 \mid \theta_j)]^{(1-u_{ij})} \\ &= \prod_{j=1}^n \prod_{i=1}^l [P(U_{ij} = 1 \mid \theta_j)]^{u_{ij}} [1 - P(U_{ij} = 1 \mid \theta_j)]^{(1-u_{ij})} \end{aligned}$$

# Estimação dos parâmetros dos itens e das habilidades

No processo de estimação dos parâmetros, podemos ter as seguintes situações:

- As habilidades  $\theta_1, \dots, \theta_n$  são conhecidas e queremos estimar os parâmetros dos itens  $\gamma_1, \dots, \gamma_I$ ;
- Os parâmetros dos itens  $\gamma_1, \dots, \gamma_I$  são conhecidos e queremos estimar as habilidades  $\theta_1, \dots, \theta_n$ ;
- Os parâmetros dos itens e as habilidades são desconhecidos e queremos fazer a estimação conjunta de  $\gamma_1, \dots, \gamma_I$  e  $\theta_1, \dots, \theta_n$ .

Em todas as situações, a estimação dos parâmetros tem que ser feita através de processos iterativos. A partir de estimativas iniciais dos parâmetros, novas estimativas são obtidas a cada iteração até obter convergência para o ponto de máximo da função de log-verossimilhança. Em casos reais, podem acontecer problemas de não convergência do algoritmo. Além disso, a convergência pode depender do ponto inicial adotado na aplicação do algoritmo. O algoritmo mais comum para cálculo de estimativas de máxima verossimilhança (EMV) é o algoritmo de Newton-Raphson, ou o algoritmo scoring de Fisher, quando a matriz de segundas derivadas da logverossimilhança é substituída por sua esperança (i.e., pela matriz de informação com sinal invertido). A aplicação de tais algoritmos pode, ainda, fornecer estimadores não consistentes. Para evitar tais problemas, algoritmos alternativos foram propostos.

# Parâmetros dos itens com proficiências conhecidas

Com a suposição de independência entre os indivíduos e entre os itens, podemos estimar os parâmetros de cada item separadamente. Algoritmo de Newton-Raphson: a  $(k + 1)$ -ésima estimativa dos parâmetros dos itens é obtida a partir da  $k$ -ésima estimativa através da expressão

$$\hat{\gamma}_i^{(k+1)} = \hat{\gamma}_i^{(k)} - H^{-1}(\hat{\gamma}_i^{(k)}) \nabla \mathcal{L}(\hat{\gamma}_i^{(k)}).$$

Aqui,  $k$  é o índice da iteração,  $H$  é a matriz hessiana (matriz de segundas derivadas) da log-verossimilhança com relação aos parâmetros do  $i$ -ésimo item, e  $\nabla \mathcal{L}$  é o vetor gradiente (vetor de primeiras derivadas) da log-verossimilhança com relação aos parâmetros do  $i$ -ésimo item,



As estimativas iniciais  $\gamma_i^{(0)}$  podem ser obtidas a partir das expressões  $\rho_i^{PB} = a_i / \sqrt{1 + a_i^2}$  e  $\nu_i = b_i \rho_i^{PB}$ , com  $\Phi(-\nu_i) = \pi_i$ , sendo  $\pi_i$  a proporção de respostas positivas para o  $i$ -ésimo item,  $\rho_i^{PB}$  o coeficiente de correlação ponto-bisserial para o  $i$ -ésimo item e  $\Phi(\cdot)$  é a f.d.a. da distribuição  $N(0, 1)$ . A estimativa inicial de  $c_i$  pode ser dada pelo inverso do número de alternativas de respostas do item.

Esse método apresenta problema quando  $u_{ij} = 0, j = 1, \dots, n$ . Neste caso, a verossimilhança  $L(\gamma_i)$  é função extritamente crescente de  $b_i$ . Consequentemente, teríamos  $\hat{b}_i = \infty$ .

De maneira análoga, se  $u_{ij} = 1, i = 1, \dots, I$ ,  $L(\gamma_i)$  é função extritamente decrescente de  $b_i$ . Consequentemente, teríamos  $\hat{b}_i = -\infty$ .

Este problema pode ser evitado através da estimação bayesiana, assumindo uma distribuição *a priori* para cada parâmetro. Em geral, tomamos  $a_i \sim \text{lognormal}(\mu_i, \sigma_i^2)$ ,  $b_i \sim N(\mu_b, \sigma_b)$  e  $c_i \sim \text{Beta}(\alpha_c, \beta_c)$ . As estimativas bayesianas EAP (esperança a posteriori) ou MAP (moda a posteriori) podem ser obtidas via MCMC (Markov Chain Monte Carlo).

# Proficiências com parâmetros dos itens conhecidos

Com a suposição de independência local e entre os itens, podemos estimar a proficiência de cada indivíduo separadamente.

Algoritmo de Newton-Raphson: a  $(k + 1)$ -ésima estimativa da proficiência é obtida a partir da  $k$ -ésima estimativa através da expressão

$$\hat{\theta}_j^{(k+1)} = \hat{\theta}_j^{(k)} - H^{-1}(\hat{\theta}_j^{(k)})h(\hat{\theta}_j^{(k)}).$$

Aqui,  $k$  é o índice da iteração,  $H$  é a segunda derivada da log-verossimilhança com relação a  $\theta_j$ , e  $h$  é a primeira derivada da log-verossimilhança com relação a  $\theta_j$ .

A estimativa inicial  $\hat{\theta}_j^{(0)}$  pode ser dada pelo escore padronizado  $(T_j - m)/s$ , sendo  $T_j$  o escore do  $j$ -ésimo indivíduo,  $m$  o escore médio de todos os respondentes, e  $s$  o desvio padrão do escore de todos os respondentes.

Esse método apresenta problema quando  $u_{ij} = 0, i = 1, \dots, I$ . Neste caso, a verossimilhança  $L(\theta_j)$  é função extritamente decrescente de  $\theta_j$ . Consequentemente, teríamos  $\hat{\theta}_j = -\infty$ . De maneira análoga, se  $u_{ij} = 1, i = 1, \dots, I$ ,  $L(\theta_j)$  é função extritamente crescente de  $\theta_j$ . Consequentemente, teríamos  $\hat{\theta}_j = \infty$ .

Este problema pode ser evitado através da estimação bayesiana, assumindo uma distribuição *a priori* para a proficiência  $\theta_j$ . Em geral, tomamos  $\theta_j \sim N(0, 1)$ . A estimativa bayesiana EAP (esperança a posteriori) ou MAP (moda a posteriori) podem ser obtidas via MCMC (Markov Chain Monte Carlo).

# Máxima Verossimilhança Marginal

Neste método, assume-se uma distribuição de probabilidade  $g(\theta | \eta)$  para a proficiência populacional, onde  $\eta$  representa o vetor de parâmetros desta distribuição. Comumente, adota-se a distribuição  $N(0, 1)$ , mas outros modelos podem ser considerados. As estimativas dos parâmetros dos itens  $\gamma$  são dadas pelo ponto de máximo de

$$L(\gamma, \eta) = P(u_{..} | \gamma, \eta) = \prod_{j=1}^n P(u_{.j} | \gamma, \eta)$$

sendo

$$\begin{aligned} P(u_{.j} | \gamma, \eta) &= \int_{-\infty}^{\infty} P(u_{.j} | \theta, \gamma, \eta) g(\theta | \eta) d\theta \\ &= \int_{-\infty}^{\infty} P(u_{.j} | \theta, \gamma) g(\theta | \eta) d\theta \end{aligned}$$

Aqui, mesmo com a suposição de independência entre os itens, a estimação dos parâmetros dos itens tem que ser feita conjuntamente para os parâmetros de todos os itens, ou seja, o método é bastante trabalhoso computacionalmente. Utiliza-se o algoritmo de Newton-Raphson.

Mais detalhes podem ser encontrados em:

- Andrade, D.F., Tavares, H.R. e Valle, R.C., (2000). Teoria da Resposta ao Item: Conceitos e Aplicações, 14<sup>0</sup> SINAPE, ABE.
- Baker, F.B., Kim, S.H., (2004). Item Response Theory, Parameter Estimation Techniques, 2nd ed., Marcel Dekker.

Vamos assumir as distribuições *a priori*  $\gamma \sim f(\cdot \mid \tau)$  e  $\theta \sim g(\cdot \mid \eta)$ , e também que  $\gamma$  e  $\theta$  são independentes, i.e., que a distribuição *a priori* conjunta de  $\gamma$  e  $\theta$  é dada por

$$f(\theta, \gamma \mid \tau, \eta) = f(\gamma \mid \tau)g(\theta \mid \eta)$$

Então,

$$f(\theta, \gamma \mid u_{..}) \propto L(u_{..} \mid \theta, \gamma)f(\cdot \mid \tau)g(\cdot \mid \eta),$$

sendo  $u_{..} = (u_{ij}; j = 1, \dots, n; i = 1, \dots, l)$ , e

$$L(u_{..} \mid \theta, \gamma) = \prod_{i=1}^l \prod_{j=1}^n P(U_{ij} = u_{ij} \mid \theta, \gamma).$$

Temos que encontrar

$$\begin{aligned}\hat{a}_i &= \arg \max_{a_i} \{ \log L(u_{..} \mid \theta, \gamma) + \log f(\gamma \mid \tau) \} \\ \hat{b}_i &= \arg \max_{b_i} \{ \log L(u_{..} \mid \theta, \gamma) + \log f(\gamma \mid \tau) \} \\ \hat{c}_i &= \arg \max_{c_i} \{ \log L(u_{..} \mid \theta, \gamma) + \log f(\gamma \mid \tau) \} \\ \hat{\theta}_j &= \arg \max_{\theta_j} \{ \log L(u_{.j} \mid \theta_j, \gamma) + \log g(\theta_j \mid \tau) \}\end{aligned}$$

sendo  $u_{.j} = (u_{ij}; i = 1, \dots, I)$ .



As estimativas são obtidas utilizando algoritmos de maximização (Newton-Raphson ou scoring de Fisher) para obter as soluções das equações:

$$\begin{aligned}\frac{\partial \log L(u_{..} \mid \theta, \gamma)}{\partial a_i} + \frac{\partial \log f(\gamma \mid \tau)}{\partial a_i} &= 0; \\ \frac{\partial \log L(u_{..} \mid \theta, \gamma)}{\partial b_i} + \frac{\partial \log f(\gamma \mid \tau)}{\partial b_i} &= 0; \\ \frac{\partial \log L(u_{..} \mid \theta, \gamma)}{\partial c_i} + \frac{\partial \log f(\gamma \mid \tau)}{\partial c_i} &= 0; \\ \frac{\partial \log L(u_{.j} \mid \theta_j, \gamma)}{\partial \theta_j} + \frac{\partial \log g(\theta_j \mid \tau)}{\partial \theta_j} &= 0.\end{aligned}$$